# Customer Shopping Behavior Analysis

### *0. Customer_Shopping_Behavior.csv:*

***1. Linhas:*** *3900*
***2. Colunas:*** *18*
***3. Key Features:***
- ***Identificação:***
  - *Customer ID* (Identificador único para cada cliente).
- ***Dados demográficos dos clientes:***
  - *Age* (Idade do cliente);
  - *Gender* (Gênero do cliente);
  - *Location* (Estado ou região onde o cliente reside (nos EUA, no caso deste dataset)).
- ***Detalhes da compra e do produto:***
  - *Item Purchased* (Item específico comprado);
  - Category (Categoria geral do item);
  - *Purchase Amount (USD)* (Valor da transação em dólares);
  - *Size* (Tamanho do item comprado);
  - *Color* (Cor do item);
  - *Season* (Estação do ano em que a compra foi feita).
- ***Experiência:***
  - *Review Rating:* A nota dada pelo cliente ao produto (geralmente de 1 a 5).
- ***Fidelidade:***
  - *Subscription Status* (Se o cliente tem uma assinatura ativa com a loja);
  - *Previous Purchases* (Número de compras que este cliente já realizou anteriormente);
  - *Frequency of Purchases* (Frequência com que o cliente costuma comprar).
- ***Pagamento:***
  - *Shipping Type* (Método de envio escolhido);
  - *Discount Applied* (Indica se algum desconto foi aplicado à compra);
  - *Promo Code Used* (Indica se um código promocional foi utilizado);
  - *Payment Method* (Forma de pagamento utilizada).

***4. Valores nulos:*** *37 em Review Rating.*

### *1. ETL - Extração, Transformação e Carga (Python):*

***1. Imports:*** As bibliotecas pandas, sqlalchemy, pymysql e ipykernel foram instaladas, e a primeira e segunda citadas foram importadas;

***2. Carregando o conjunto de dados:*** Após carregar o conjunto de dados da pasta data/raw, df.info() e df.head() foram utilizadas para exibir informações e mostrar as cinco primeiras linhas do dataset, respectivamente;

***3. Pré-processamento dos dados:*** As estatísticas básicas foram exploradas com df.describe(include='all'), para incluir também as colunas categóricas; foi verificado que a

coluna Rating Review possuía 37 linhas com valores nulos, os quais foram substituídos pela mediana de sua respectiva categoria; o nome das colunas foi padronizado, trocando letras secretas por minúsculas e espaços por "_" e retirando (USD) de Purchase Amount;

| | Customer ID | Age | Gender | Item Purchased | Category | Purchase Amount (USD) | Location | Size | Color | Season | Review Rating | Subscription Status | Shipping Type | Discount Applied | Promo Code Used |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| count | 3900.000000 | 3900.000000 | 3900 | 3900 | 3900 | 3900.000000 | 3900 | 3900 | 3900 | 3900 | 3863.000000 | 3900 | 3900 | 3900 | 3900 |
| unique | NaN | NaN | 2 | 25 | 4 | NaN | 50 | 4 | 25 | 4 | NaN | 2 | 6 | 2 | 2 |
| top | NaN | NaN | Male | Blouse | Clothing | NaN | Montana | M | Olive | Spring | NaN | No | Free Shipping | No | No |
| freq | NaN | NaN | 2652 | 171 | 1737 | NaN | 96 | 1755 | 177 | 999 | NaN | 2847 | 675 | 2223 | 2223 |
| mean | 1950.500000 | 44.068462 | NaN | NaN | NaN | 59.764359 | NaN | NaN | NaN | NaN | 3.750065 | NaN | NaN | NaN | NaN |
| std | 1125.977353 | 15.207589 | NaN | NaN | NaN | 23.685392 | NaN | NaN | NaN | NaN | 0.716983 | NaN | NaN | NaN | NaN |
| min | 1.000000 | 18.000000 | NaN | NaN | NaN | 20.000000 | NaN | NaN | NaN | NaN | 2.500000 | NaN | NaN | NaN | NaN |
| 25% | 975.750000 | 31.000000 | NaN | NaN | NaN | 39.000000 | NaN | NaN | NaN | NaN | 3.100000 | NaN | NaN | NaN | NaN |
| 50% | 1950.500000 | 44.000000 | NaN | NaN | NaN | 60.000000 | NaN | NaN | NaN | NaN | 3.800000 | NaN | NaN | NaN | NaN |
| 75% | 2925.250000 | 57.000000 | NaN | NaN | NaN | 81.000000 | NaN | NaN | NaN | NaN | 4.400000 | NaN | NaN | NaN | NaN |
| max | 3900.000000 | 70.000000 | NaN | NaN | NaN | 100.000000 | NaN | NaN | NaN | NaN | 5.000000 | NaN | NaN | NaN | NaN |

| Previous Purchases | Payment Method | Frequency of Purchases |
|---|---|---|
| 3900.000000 | 3900 | 3900 |
| NaN | 6 | 7 |
| NaN | PayPal | Every 3 Months |
| NaN | 677 | 584 |
| 25.351538 | NaN | NaN |
| 14.447125 | NaN | NaN |
| 1.000000 | NaN | NaN |
| 13.000000 | NaN | NaN |
| 25.000000 | NaN | NaN |
| 38.000000 | NaN | NaN |
| 50.000000 | NaN | NaN |

***4. Manipulando colunas:*** As colunas age_group e purchase_frequency_days foram criadas para padronizar as idades em quatro grupos e mostrar a frequência de compras em dias; foi verificado que as colunas discount_applied e promo_code_used eram iguais, portanto, a segunda foi removida;

***5. Exportando o csv:*** O dataset limpo e transformado foi exportando para a coluna data/processed;

***6. Conectando ao MySQL:*** Foi estabelecida conexão do Python com o MySQL, com a tabela sendo carregada para a análise no SQL, que foi feita no phpMyAdmin.

## *2. Análise de Dados (SQL):*

***1.*** *Qual é a receita total gerada por clientes do sexo masculino em comparação com clientes do sexo feminino?*

| gender | purchase_sum 1 |
|---|---|
| Male | 157890 |
| Female | 75191 |

***2.*** *Quais clientes usaram um desconto, mas ainda gastaram mais do que o valor médio de compra?*

| customer_id | purchase_amount |
|---|---|
| 7 | 85 |
| 9 | 97 |
| 12 | 68 |
| 13 | 72 |
| 16 | 81 |
| 20 | 90 |
| 22 | 62 |
| 24 | 88 |
| 29 | 94 |
| 32 | 79 |
| 33 | 67 |
| 35 | 91 |
| 37 | 69 |
| 40 | 60 |
| 41 | 76 |
| 43 | 100 |
| 44 | 69 |
| 55 | 94 |
| 57 | 73 |
| 58 | 64 |
| 60 | 79 |
| 62 | 68 |

Total de clientes: 839

***3.*** *Quais são os 5 produtos com a maior classificação média de avaliação?*

| item_purchased | review_mean |
|---|---|
| Gloves | 3.86 |
| Sandals | 3.84 |
| Boots | 3.82 |
| Hat | 3.80 |
| Skirt | 3.78 |

***4.*** *Comparando os valores médios de compra entre o frete padrão e o frete expresso.*

| shipping_type | purchase_mean 1 |
|---|---|
| Express | 60.48 |
| Standard | 58.46 |

***5.*** *Os clientes assinantes gastam mais? Comparando o gasto médio e a receita total entre assinantes e não assinantes.*

| subscription_status | customer_total | purchase_mean 2 | purchase_total 1 |
|---|---|---|---|
| No | 2847 | 59.87 | 170436.00 |
| Yes | 1053 | 59.49 | 62645.00 |

Os clientes não assinantes têm um gasto médio e receita total maiores que os clientes assinantes.

***6.*** *Quais são os 5 produtos com a maior porcentagem de compras com descontos aplicados?*

| item_purchased | discount_applied 1 |
|---|---|
| Hat | 50.00 |
| Sneakers | 49.66 |
| Coat | 49.07 |
| Sweater | 48.17 |
| Pants | 47.37 |

***7.*** *Segmentando os clientes em Novos, Recorrentes e Fiéis com base no número total de compras anteriores e mostre a contagem de cada segmento.*

| client_type | client_count 1 |
|---|---|
| Loyal | 3116 |
| Returning | 701 |
| New | 83 |

***8.*** *Quais são os 3 produtos mais comprados em cada categoria?*

| category | item_purchased | purchase_total | ranking |
|---|---|---|---|
| Accessories | Belt | 161 | 3 |
| Accessories | Jewelry | 171 | 1 |
| Accessories | Sunglasses | 161 | 2 |
| Clothing | Blouse | 171 | 1 |
| Clothing | Pants | 171 | 2 |
| Clothing | Shirt | 169 | 3 |
| Footwear | Sandals | 160 | 1 |
| Footwear | Shoes | 150 | 2 |
| Footwear | Sneakers | 145 | 3 |
| Outerwear | Coat | 161 | 2 |
| Outerwear | Jacket | 163 | 1 |

***9.*** *Os clientes que compram repetidamente (mais de 5 compras anteriores) também têm maior probabilidade de assinar?*

| customers 1 | subscription_status |
|---|---|
| 2518 | No |
| 958 | Yes |

Não Assinantes: 2.518
Assinantes: 958
Total: 3.476
Taxa de Assinatura: Apenas 27,5% desse grupo é assinante

Portanto, mais de 5 compras anteriores não faz a probabilidade de assinar ser maior.

***10.*** *Qual é a contribuição de cada faixa etária para a receita?*

| age_group | purchase_amount 1 |
|---|---|
| Young Adult | 62143 |
| Middle-aged | 59197 |
| Adult | 55978 |
| Senior | 55763 |

## *3. Dashboard (Power BI):*

Dashboard interativo construído no Power BI:

## *4. Recomendações de Negócios:*

***1.*** Clientes masculinos concentram 67,74% da receita. Recomenda-se ampliar o portfólio feminino e investir em campanhas segmentadas para esse público, buscando uma distribuição mais equilibrada;

***2.*** Apenas 21,51% dos clientes com desconto compraram acima da média, indicando que os descontos não estão elevando o ticket. Recomenda-se adotar descontos progressivos ou vinculados a um valor mínimo de compra;

***3.*** Nenhum produto atingiu média superior a 4,0. Recomenda-se priorizar a revisão de fornecedores ou substituição de produtos;

***4.*** 79,90% dos clientes são fiéis, mas apenas 25,7% assinam — e esses representam somente 26,87% da receita. Há um gap claro entre fidelização e conversão. Recomenda-se tornar os benefícios da assinatura mais atrativos e comunicá-los ativamente à base fiel.