Customer Shopping Behavior Analysis

0. Customer_Shopping_Behavior.csv:

1. Linhas: *3900*
2. Colunas: *18*
3. Key Features:
- ***Identificação:***
  - *Customer ID* (Identificador único para cada cliente).
- ***Dados demográficos dos clientes:***
  - *Age* (Idade do cliente);
  - *Gender* (Gênero do cliente);
  - *Location* (Estado ou região onde o cliente reside (nos EUA, no caso deste dataset)).
- ***Detalhes da compra e do produto:***
  - *Item Purchased* (Item específico comprado);
  - Category (Categoria geral do item);
  - *Purchase Amount (USD)* (Valor da transação em dólares);
  - *Size* (Tamanho do item comprado);
  - *Color* (Cor do item);
  - *Season* (Estação do ano em que a compra foi feita).
- ***Experiência:***
  - *Review Rating* (A nota dada pelo cliente ao produto.
- ***Fidelidade:***
  - *Subscription Status* (Se o cliente tem uma assinatura ativa com a loja);
  - *Previous Purchases* (Número de compras que este cliente já realizou anteriormente);
  - *Frequency of Purchases* (Frequência com que o cliente costuma comprar).
- ***Pagamento:***
  - *Shipping Type* (Método de envio escolhido);
  - *Discount Applied* (Indica se algum desconto foi aplicado à compra);
  - *Promo Code Used* (Indica se um código promocional foi utilizado);
  - *Payment Method* (Forma de pagamento utilizada).

4. Valores nulos: *37 em Review Rating.*

1. ETL - Extração, Transformação e Carga (Python):

1. Imports: As bibliotecas pandas, sqlalchemy, pymysql e ipykernel foram instaladas, e a primeira e segunda citadas foram importadas;

2. Carregando o conjunto de dados: Após carregar o conjunto de dados da pasta data/raw, df.info() e df.head() foram utilizadas para exibir informações e mostrar as cinco primeiras linhas do dataset, respectivamente;

3. Pré-processamento dos dados: As estatísticas básicas foram exploradas com df.describe(include='all'), para incluir também as colunas categóricas; foi verificado que a

coluna Rating Review possuía 37 linhas com valores nulos, os quais foram substituídos pela mediana de sua respectiva categoria; o nome das colunas foi padronizado, trocando letras secretas por minúsculas e espaços por "_" e retirando (USD) de Purchase Amount;

	Customer ID	Age	Gender	Item Purchased	Category	Purchase Amount (USD)	Location	Size	Color	Season	Review Rating	Subscription Status	Shipping Type	Discount Applied	Promo Code Used
count	3900.000000	3900.000000	3900	3900	3900	3900.000000	3900	3900	3900	3900	3863.000000	3900	3900	3900	3900
unique	NaN	NaN	2	25	4	NaN	50	4	25	4	NaN	2	6	2	2
top	NaN	NaN	Male	Blouse	Clothing	NaN	Montana	M	Olive	Spring	NaN	No	Free Shipping	No	No
freq	NaN	NaN	2652	171	1737	NaN	96	1755	177	999	NaN	2847	675	2223	2223
mean	1950.500000	44.068462	NaN	NaN	NaN	59.764359	NaN	NaN	NaN	NaN	3.750065	NaN	NaN	NaN	NaN
std	1125.977353	15.207589	NaN	NaN	NaN	23.685392	NaN	NaN	NaN	NaN	0.716983	NaN	NaN	NaN	NaN
min	1.000000	18.000000	NaN	NaN	NaN	20.000000	NaN	NaN	NaN	NaN	2.500000	NaN	NaN	NaN	NaN
25%	975.750000	31.000000	NaN	NaN	NaN	39.000000	NaN	NaN	NaN	NaN	3.100000	NaN	NaN	NaN	NaN
50%	1950.500000	44.000000	NaN	NaN	NaN	60.000000	NaN	NaN	NaN	NaN	3.800000	NaN	NaN	NaN	NaN
75%	2925.250000	57.000000	NaN	NaN	NaN	81.000000	NaN	NaN	NaN	NaN	4.400000	NaN	NaN	NaN	NaN
max	3900.000000	70.000000	NaN	NaN	NaN	100.000000	NaN	NaN	NaN	NaN	5.000000	NaN	NaN	NaN	NaN

Previous Purchases	Payment Method	Frequency of Purchases
3900.000000	3900	3900
NaN	6	7
NaN	PayPal	Every 3 Months
NaN	677	584
25.351538	NaN	NaN
14.447125	NaN	NaN
1.000000	NaN	NaN
13.000000	NaN	NaN
25.000000	NaN	NaN
38.000000	NaN	NaN
50.000000	NaN	NaN

4. Manipulando colunas: As colunas age_group e purchase_frequency_days foram criadas para padronizar as idades em quatro grupos e mostrar a frequência de compras em dias; foi verificado que as colunas discount_applied e promo_code_used eram iguais, portanto, a segunda foi removida;

5. Exportando o csv: O dataset limpo e transformado foi exportando para a coluna data/processed;

6. Conectando ao MySQL: Foi estabelecida conexão do Python com o MySQL, com a tabela sendo carregada para a análise no SQL, que foi feita no phpMyAdmin.

2. Análise de Dados (SQL):

1. *Qual é a receita total gerada por clientes do sexo masculino em comparação com clientes do sexo feminino?*

gender	purchase_sum 1
Male	157890
Female	75191

2. *Quais clientes usaram um desconto, mas ainda gastaram mais do que o valor médio de compra?*

customer_id	purchase_amount
7	85
9	97
12	68
13	72
16	81
20	90
22	62
24	88
29	94
32	79
33	67
35	91
37	69
40	60
41	76
43	100
44	69
55	94
57	73
58	64
60	79
62	68

Total de clientes: 839

3. *Quais são os 5 produtos com a maior classificação média de avaliação?*

item_purchased	review_mean
Gloves	3.86
Sandals	3.84
Boots	3.82
Hat	3.80
Skirt	3.78

4. *Comparando os valores médios de compra entre o frete padrão e o frete expresso.*

shipping_type	purchase_mean 1
Express	60.48
Standard	58.46

5. *Os clientes assinantes gastam mais? Comparando o gasto médio e a receita total entre assinantes e não assinantes.*

subscription_status	customer_total	purchase_mean 2	purchase_total 1
No	2847	59.87	170436.00
Yes	1053	59.49	62645.00

Os clientes não assinantes têm um gasto médio e receita total maiores que os clientes assinantes.

6. *Quais são os 5 produtos com a maior porcentagem de compras com descontos aplicados?*

item_purchased	discount_applied 1
Hat	50.00
Sneakers	49.66
Coat	49.07
Sweater	48.17
Pants	47.37

7. *Segmentando os clientes em Novos, Recorrentes e Fiéis com base no número total de compras anteriores e mostre a contagem de cada segmento.*

client_type	client_count 1
Loyal	3116
Returning	701
New	83

8. *Quais são os 3 produtos mais comprados em cada categoria?*

category	item_purchased	purchase_total	ranking
Accessories	Belt	161	3
Accessories	Jewelry	171	1
Accessories	Sunglasses	161	2
Clothing	Blouse	171	1
Clothing	Pants	171	2
Clothing	Shirt	169	3
Footwear	Sandals	160	1
Footwear	Shoes	150	2
Footwear	Sneakers	145	3
Outerwear	Coat	161	2
Outerwear	Jacket	163	1

9. *Os clientes que compram repetidamente (mais de 5 compras anteriores) também têm maior probabilidade de assinar?*

customers 1	subscription_status
2518	No
958	Yes

Não Assinantes: 2.518
Assinantes: 958
Total: 3.476
Taxa de Assinatura: Apenas 27,5% desse grupo é assinante

Portanto, mais de 5 compras anteriores não faz a probabilidade de assinar ser maior.

10. *Qual é a contribuição de cada faixa etária para a receita?*

age_group	purchase_amount 1
Young Adult	62143
Middle-aged	59197
Adult	55978
Senior	55763

3. Dashboard (Power BI):

Dashboard interativo construído no Power BI:

4. Recomendações de Negócios:

1. Clientes masculinos concentram 67,74% da receita. Recomenda-se ampliar o portfólio feminino e investir em campanhas segmentadas para esse público, buscando uma distribuição mais equilibrada;

2. Apenas 21,51% dos clientes com desconto compraram acima da média, indicando que os descontos não estão elevando o ticket. Recomenda-se adotar descontos progressivos ou vinculados a um valor mínimo de compra;

3. Nenhum produto atingiu média superior a 4,0. Recomenda-se priorizar a revisão de fornecedores ou substituição de produtos;

4. 79,90% dos clientes são fiéis, mas apenas 25,7% assinam — e esses representam somente 26,87% da receita. Há um gap claro entre fidelização e conversão. Recomenda-se tornar os benefícios da assinatura mais atrativos e comunicá-los ativamente à base fiel.